

## ESTADÍSTICA APLICADA II

Tarea No. 1

Dr. Víctor M. Guerrero  
Ago-Dic, 2021

1. En los siguientes modelos, el término  $\varepsilon_i$  representa el error aleatorio y se supone que se cuenta con una muestra de  $n$  datos, de manera que  $i = 1, \dots, n$ . **Determine:** (i) ¿Cuáles son lineales en los parámetros  $\beta_0$  y  $\beta_1$ ? (ii) ¿Cuáles son lineales en las variables  $Y$  y  $X$ ? (iii) ¿Cuáles podrían considerarse modelos de regresión lineal simple? (posiblemente con variables transformadas).

(a)  $Y_i = \beta_0 + \beta_1/X_i + \varepsilon_i$

(b)  $Y_i = \beta_0 + \beta_1 \log(X_i) + \varepsilon_i$

(c)  $Y_i = \beta_0 X_i^{\beta_1}$

(d)  $\log(Y_i) = \log(\beta_0) + \beta_1 \log(X_i) + \varepsilon_i$

(e)  $Y_i = \beta_0 + \beta_1 \varepsilon_i$

2. **Demuestre** que el estimador mínimo-cuadrático de  $\beta_1$  en un modelo de regresión lineal simple, se puede escribir como

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

y que

$$\sum (Y_i - \hat{Y}_i) \hat{Y}_i = 0.$$

3. A partir de una muestra de  $n = 200$  parejas de observaciones, se calcularon las siguientes cantidades:

$$\sum X_i = 11.34, \quad \sum Y_i = 20.72, \quad \sum X_i^2 = 12.16, \quad \sum Y_i^2 = 84.96 \quad \text{y} \quad \sum X_i Y_i = 22.13$$

Con base en estas cantidades, **estime** las dos regresiones

$$\hat{Y}_i = b_0 + b_1 X_i \quad \text{y} \quad \hat{X}_i = a_0 + a_1 Y_i.$$

**Deduzca** una recta estimada para  $Y$  a partir de la segunda ecuación.

**Grafique** las dos rectas estimadas de  $Y$  en la misma gráfica y **comente** acerca de ellas, en particular acerca de cómo se podrían interpretar las mismas y por qué difieren.

1. En los siguientes modelos, el término  $\varepsilon_i$  representa el error aleatorio y se supone que se cuenta con una muestra de  $n$  datos, de manera que  $i = 1, \dots, n$ . **Determine:** (i) ¿Cuáles son lineales en los parámetros  $\beta_0$  y  $\beta_1$ ? (ii) ¿Cuáles son lineales en las variables  $Y$  y  $X$ ? (iii) ¿Cuáles podrían considerarse modelos de regresión lineal simple? (posiblemente con variables transformadas).

(a)  $Y_i = \beta_0 + \beta_1/X_i + \varepsilon_i$

i) linealidad en los parámetros:

$$\frac{\partial Y_i}{\partial \beta_0} = 1$$


$$\frac{\partial Y_i}{\partial \beta_1} = \frac{1}{X_i}$$

$$\frac{\partial Y_i}{\partial \beta_1} = \frac{1}{X_i}$$

no hay interacción entre los parámetros : el modelo es lineal en los parámetros

ii) linealidad en las variables:

$$Y_i = \beta_0 + \frac{\beta_1}{X_i} + \varepsilon_i$$



∴ no es lineal en las variables

iii) ¿Es modelo de regresión lineal simple?

- es lineal en los parámetros ✓
- solo tiene una variable explicativa ( $X_i$ ) ✓
- ∴ sí es un modelo de regresión lineal simple

(b)  $Y_i = \beta_0 + \beta_1 \log(X_i) + \varepsilon_i$

i) linealidad en los parámetros:

$$\frac{\partial Y_i}{\partial \beta_0} = 1$$

$$\frac{\partial Y_i}{\partial \beta_1} = \ln(X_i)$$


$$\frac{\partial Y_i}{\partial \beta_1} = \ln(X_i)$$

$$\frac{\partial Y_i}{\partial \beta_1}$$

no hay interacción entre los parámetros : el modelo es lineal en los parámetros

ii) linealidad en las variables:

$$Y_i = \beta_0 + \beta_1 \ln(X_i) + \varepsilon_i$$



∴ no es lineal en las variables

iii) ¿Es modelo de regresión lineal simple?

- es lineal en los parámetros ✓
- solo tiene una variable explicativa ( $X_i$ ) ✓
- ∴ sí es un modelo de regresión lineal simple

(c)  $Y_i = \beta_0 X_i^{\beta_1}$

i) linealidad en los parámetros:

$$\frac{\partial Y_i}{\partial \beta_0} = X_i^{\beta_1}$$

$$\frac{\partial Y_i}{\partial \beta_1} = \beta_0 \cdot \beta_1 X_i^{(\beta_1-1)}$$



$$\frac{\partial Y_i}{\partial \beta_1} = \beta_0 \cdot \beta_1 X_i^{(\beta_1-1)}$$

$$\frac{\partial Y_i}{\partial \beta_1}$$

hay interacción entre los parámetros : el modelo no es lineal en los parámetros

ii) linealidad en las variables:

$$Y_i = \beta_0 \cdot X_i^{\beta_1}$$



∴ si  $\beta_1 = 1 \Rightarrow$  sí es lineal en las variables

si  $\beta_1 > 1 \Rightarrow$  no es lineal en las variables

iii) ¿Es modelo de regresión lineal simple?

- es lineal en los parámetros ✗
- solo tiene una variable explicativa ( $X_i$ ) ✓
- ∴ no es un modelo de regresión lineal simple

(d)  $\log(Y_i) = \log(\beta_0) + \beta_1 \log(X_i) + \varepsilon_i$

$$\ln(Y_i) = \ln(\beta_0) + \ln(X_i^{\beta_1}) + \varepsilon_i$$

$$= \ln(\beta_0 \cdot X_i^{\beta_1}) + \varepsilon_i$$

$$\Rightarrow Y_i = \beta_0 \cdot X_i^{\beta_1} \cdot e^{\varepsilon_i}$$

i) linealidad en los parámetros:

$$\frac{\partial Y_i}{\partial \beta_0} = X_i^{\beta_1} \cdot e^{\varepsilon_i}$$

$$\frac{\partial Y_i}{\partial \beta_1}$$



$$= \beta_0 \cdot \beta_1 \cdot e^{\varepsilon_i} \cdot X_i^{(\beta_1-1)}$$

$$\frac{\partial Y_i}{\partial \beta_1}$$

hay interacción entre los parámetros : el modelo no es lineal en los parámetros

ii) linealidad en las variables:

$$Y_i = \beta_0 \cdot X_i^{\beta_1} \cdot e^{\varepsilon_i}$$



$\therefore$  si  $\beta_1 = 1 \Rightarrow$  sí es lineal en las variables  
si  $\beta_1 > 1 \Rightarrow$  no es lineal en las variables

iii) ¿Es modelo de regresión lineal simple?

- es lineal en los parámetros X
- solo tiene una variable explicativa ( $X_i$ ) /
- $\therefore$  no es un modelo de regresión lineal simple

(e)  $Y_i = \beta_0 + \beta_1 \varepsilon_i$

i) linealidad en los parámetros:

$$\frac{\partial Y_i}{\partial \beta_0} = 1$$


$$\frac{\partial Y_i}{\partial \beta_1}$$

$$= \varepsilon_i$$

$$\frac{\partial Y_i}{\partial \beta_1}$$

ii) linealidad en las variables:

$$Y_i = \beta_0 + \beta_1 \varepsilon_i$$



El modelo no se puede expresar como combinación lineal ni de los parámetros con las variables, ni viceversa.  $\therefore$  No es lineal en los parámetros, ni en las variables.

iii) ¿Es modelo de regresión lineal simple?

- es lineal en los parámetros  $\times$
- solo tiene una variable explicativa ( $X_i$ )  $\times$
- ∴ no es un modelo de regresión lineal simple

2. **Demuestre** que el estimador mínimo-cuadrático de  $\beta_1$  en un modelo de regresión lineal simple, se puede escribir como

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

y que

$$\sum (Y_i - \hat{Y}_i) \hat{Y}_i = 0.$$

i) P.d:

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad \left\{ \begin{array}{l} * \\ * \end{array} \right.$$

Dem:

Sea  $b_1$  el estimador mínimo cuadrático de  $\beta_1$  + la suma de cuadrados residual (SCR) es mínima, i.e:  $SCR = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$  es mínima

$\Rightarrow$  derivamos e igualamos a cero para encontrar los puntos críticos.

$$\begin{aligned} \text{I)} \quad \frac{\partial SCR}{\partial \hat{\beta}_0} \bigg|_{\substack{\hat{\beta}_0 = b_0 \\ \hat{\beta}_1 = b_1}} &= 0 \iff \sum_{i=1}^n 2(Y_i - b_0 - b_1 X_i)(-1) = 0 \\ &\iff \sum_{i=1}^n (Y_i - b_0 - b_1 X_i) = 0 \\ &\iff \sum_{i=1}^n Y_i - nb_0 - b_1 \sum_{i=1}^n X_i = 0 \end{aligned}$$

$$\begin{aligned} \text{II)} \quad \frac{\partial SCR}{\partial \hat{\beta}_1} \bigg|_{\substack{\hat{\beta}_0 = b_0 \\ \hat{\beta}_1 = b_1}} &= 0 \iff \sum_{i=1}^n 2(Y_i - b_0 - b_1 X_i)(-X_i) = 0 \\ &\iff \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)X_i = 0 \\ &\iff \sum_{i=1}^n X_i Y_i - b_0 \sum_{i=1}^n X_i - b_1 \sum_{i=1}^n X_i^2 = 0 \end{aligned}$$

I) y II) forman el siguiente sistema de ecuaciones.

$$\begin{pmatrix} \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_i Y_i \end{pmatrix}$$

$$\Rightarrow \begin{pmatrix} b_0 \\ b_1 \end{pmatrix} = \underbrace{\begin{pmatrix} n & \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix}}^*^{-1} \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_i Y_i \end{pmatrix}$$

$$\begin{aligned} * &= \frac{1}{n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2} \begin{pmatrix} \sum_{i=1}^n X_i^2 & - \sum_{i=1}^n X_i \\ - \sum_{i=1}^n X_i & n \end{pmatrix} \\ &= \frac{1}{n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2} \begin{pmatrix} \sum_{i=1}^n X_i^2 & - \sum_{i=1}^n X_i \\ - \sum_{i=1}^n X_i & n \end{pmatrix} \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_i Y_i \end{pmatrix} \\ &= \frac{1}{n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2} \begin{pmatrix} \sum_{i=1}^n X_i^2 \sum_{i=1}^n Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n X_i Y_i \\ - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i + n \sum_{i=1}^n X_i Y_i \end{pmatrix} \end{aligned}$$

$$\Rightarrow b_1 = \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2}$$

Además,

$$\begin{aligned} * &= \sum (X_i - \bar{X})(Y_i - \bar{Y}) \\ &= \sum (X_i Y_i - X_i \bar{Y} - \bar{X} Y_i + \bar{X} \bar{Y}) \\ &= \sum X_i Y_i - \bar{Y} \sum X_i - \bar{X} \sum Y_i + n \bar{X} \bar{Y} \\ &= \sum X_i Y_i - \frac{\sum Y_i}{n} \sum X_i - \frac{\sum X_i}{n} \sum Y_i + n \left( \frac{\sum X_i}{n} \frac{\sum Y_i}{n} \right) \\ &= \sum X_i Y_i - \frac{\sum Y_i}{n} \sum X_i - \frac{\sum X_i}{n} \sum Y_i + \frac{\sum X_i \sum Y_i}{n} \\ &= \sum X_i Y_i - \frac{\sum X_i \sum Y_i}{n} \\ &= \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n} \end{aligned}$$

$$\begin{aligned}
* &= \sum (X_i - \bar{X})^2 \\
&= \sum (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\
&= \sum X_i^2 - 2\bar{X} \sum X_i + n\bar{X}^2 \\
&= \sum X_i^2 - 2\bar{X} \sum X_i + n \left( \bar{X} \frac{\sum X_i}{n} \right) \\
&= \sum X_i^2 - \cancel{2\bar{X} \sum X_i} + \cancel{\bar{X} \sum X_i} \\
&= \sum X_i^2 - \bar{X} \sum X_i \\
&= \sum X_i^2 - \frac{(\sum X_i)^2}{n} \\
&= \frac{n \sum X_i^2 - (\sum X_i)^2}{n}
\end{aligned}$$

$$\begin{aligned}
\Rightarrow b_1 &= \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2} \\
&= \frac{n \sum X_i Y_i - \sum X_i \sum Y_i}{n \sum X_i^2 - (\sum X_i)^2} \\
&= \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} //
\end{aligned}$$

ii) P.d:

$$\sum (Y_i - \hat{Y}_i) \hat{Y}_i = 0$$

Dem:

$$\begin{aligned}
\sum (Y_i - \hat{Y}_i) \hat{Y}_i &= \sum (Y_i \hat{Y}_i - \hat{Y}_i^2) \\
&= \sum Y_i \hat{Y}_i - \sum \hat{Y}_i^2 \\
&= \sum Y_i (b_0 + b_1 X_i) - \sum (b_0 + b_1 X_i)^2 \\
&= b_0 \sum Y_i + b_1 \sum X_i Y_i - \sum (b_0^2 + 2b_0 b_1 X_i + b_1^2 X_i^2) \\
&= b_0 \sum Y_i + b_1 \sum X_i Y_i - n b_0^2 - 2b_0 b_1 \sum X_i + b_0 b_1 \sum X_i + b_1^2 \sum X_i^2 \\
&= b_0 (\sum Y_i - n b_0 + b_1 \sum X_i) + b_1 (\sum X_i Y_i + b_0 \sum X_i + b_1 \sum X_i^2)
\end{aligned}$$

Recordemos las ecuaciones normales

$$A = \sum Y_i - n b_0 + b_1 \sum X_i = 0$$

$$B = \sum X_i Y_i + b_0 \sum X_i + b_1 \sum X_i^2 = 0$$

$$= 0 //$$

3. A partir de una muestra de  $n = 200$  parejas de observaciones, se calcularon las siguientes cantidades:

$$\sum X_i = 11.34, \quad \sum Y_i = 20.72, \quad \sum X_i^2 = 12.16, \quad \sum Y_i^2 = 84.96 \quad \text{y} \quad \sum X_i Y_i = 22.13$$

Con base en estas cantidades, **estime** las dos regresiones

$$\hat{Y}_i = b_0 + b_1 X_i \quad \text{y} \quad \hat{X}_i = a_0 + a_1 Y_i.$$

**Deduzca** una recta estimada para  $Y$  a partir de la segunda ecuación.

**Grafique** las dos rectas estimadas de  $Y$  en la misma gráfica y **comente** acerca de ellas, en particular acerca de cómo se podrían interpretar las mismas y por qué difieren.

$$\hat{Y}_i = b_0 + b_1 X_i$$

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{\sum X_i Y_i - \frac{\sum X_i \sum Y_i}{n}}{\sum X_i^2 - \frac{(\sum X_i)^2}{n}} = 1.8195$$

$$b_0 = \bar{Y} - b_1 \bar{X} = 0.0004$$

$$\therefore \hat{Y}_i = 0.0004 + 1.8195 X_i$$


$$\hat{X}_i = a_0 + a_1 Y_i$$

$$a_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (Y_i - \bar{Y})^2} = \frac{\sum X_i Y_i - \frac{\sum X_i \sum Y_i}{n}}{\sum Y_i^2 - \frac{(\sum Y_i)^2}{n}} = 0.25304$$

$$a_0 = \bar{X} - a_1 \bar{Y} = 0.0304$$

$$\therefore \hat{X}_i = 0.0304 + 0.25304 Y_i$$

$$\Rightarrow Y_i = -0.1205 + 3.9519 \hat{X}_i$$



Para obtener  $\hat{Y}_i$ , minimizamos las diferencias al cuadrado entre los valores observados de  $Y$  y los valores estimados de  $Y$ ; i.e: estamos minimizando distancias verticales.

Para obtener  $\hat{X}_i$ , minimizamos las diferencias al cuadrado entre los valores observados de  $X$  y los valores estimados de  $X$ ; i.e: estamos minimizando distancias horizontales.

Es de esperarse que estas rectas estimadas de  $Y$  tengan diferentes pendientes.