

En los siguientes modelos, el término  $\varepsilon_i$  representa el error aleatorio y se supone que se cuenta con una muestra de  $n$  datos, de manera que  $i = 1, \dots, n$ . Determine: (i) ¿Cuáles son lineales en los parámetros  $\beta_0$  y  $\beta_1$ ? (ii) ¿Cuáles son lineales en las variables  $Y$  y  $X$ ? (iii) ¿Cuáles podrían considerarse modelos de regresión lineal simple? (posiblemente con variables transformadas).

(a)  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$

i) Es lineal en los parámetros

$$\frac{\partial Y_i}{\partial \beta_0} = 1, \quad \frac{\partial Y_i}{\partial \beta_1} = \frac{1}{X_i}$$

ii) No es lineal en  $X_i$

$$Y_i = \beta_0 + \frac{\beta_1}{X_i} + \varepsilon_i \Leftrightarrow Y_i - \beta_0 - \varepsilon_i = \frac{\beta_1}{X_i}$$

$$\Leftrightarrow X_i = \frac{\beta_1}{Y_i - \beta_0 - \varepsilon_i}$$

No es lineal en  $Y_i$

iii) Si consideramos  $Z_i = \frac{1}{X_i}, \forall i, n$ , entonces tenemos la relación

$$Y_i = \beta_0 + \beta_1 Z_i + \varepsilon_i, \text{ la cual es regresión lineal simple porque}$$

- Lineal en los parámetros

- Solo hay una variable explicativa

(b)  $Y_i = \beta_0 + \beta_1 \log(X_i) + \varepsilon_i$

i) Es lineal en los parámetros

$$\frac{\partial Y_i}{\partial \beta_0} = 1, \quad \frac{\partial Y_i}{\partial \beta_1} = \log(X_i)$$

ii) No hay relación lineal en las variables

$$\frac{\partial Y_i}{\partial X_i} = \frac{\beta_1}{X_i}$$

iii) Si consideramos  $Z_i = \log(X_i)$  entonces

$$Y_i = \beta_0 + \beta_1 Z_i + \varepsilon_i$$

es un modelo de regresión lineal simple

- Relación lineal en los parámetros

- Solo hay una variable explicativa

(c)  $Y_i = \beta_0 X_i$

i) No es lineal en los parámetros

$$\frac{\partial Y_i}{\partial \beta_0} = X_i^{\beta_1}, \quad \frac{\partial Y_i}{\partial \beta_1} = \beta_0 \ln(\beta_1) X_i^{\beta_1}$$

ii) En general, no hay relación lineal entre  $X$  y  $Y$ . Solo se vale cuando  $\beta_1 = 1$ .

iii)  $Y_i = \beta_0 X_i^{\beta_1} \Leftrightarrow \log(Y_i) = \log(\beta_0) + \beta_1 \log(X_i)$

$\log(Y_i) \geq 0$

Si consideramos  $\tilde{Y}_i = \log(Y_i)$ ,  $\tilde{X}_i = \log(X_i)$  y  $\tilde{\beta}_0 = \log(\beta_0)$  resulta que

$$\tilde{Y}_i = \tilde{\beta}_0 + \tilde{\beta}_1 \tilde{X}_i \text{ que es regresión lineal simple.}$$

(d)  $\log(Y_i) = \log(\beta_0) + \beta_1 \log(X_i) + \varepsilon_i \quad (*)$

i) No es lineal en los parámetros.

ii) No es lineal entre  $X$  y  $Y$

iii) Si consideramos  $\tilde{Y}_i = \log(Y_i)$ ,  $\tilde{X}_i = \log(X_i)$ ,  $\tilde{\beta}_0 = \log(\beta_0)$  tenemos que

$$\tilde{Y}_i = \tilde{\beta}_0 + \tilde{\beta}_1 \tilde{X}_i + \varepsilon_i \text{ que es modelo de regresión lineal}$$

(e)  $Y_i = \beta_0 + \beta_1 \varepsilon_i \quad (**)$

i) Es lineal en los parámetros

ii) No hay relación de  $X$  con  $Y$

iii) Como esto no es modelo de regresión lineal simple.

Si:  $X_i = \varepsilon_i$  entonces

$$Y_i = \beta_0 + \beta_1 X_i \text{ que es modelo de regresión lineal simple.}$$

2. Demuestre que el estimador mínimo-cuadrático de  $\beta_1$  en un modelo de regresión lineal simple, se puede escribir como

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

y que

$$\sum (Y_i - \bar{Y}) \bar{Y}_i = 0.$$

Dem: Consideremos a  $\gamma = \hat{\beta}_0 + \hat{\beta}_1 X_i$  y sea

$$SCR = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

Objetivo:  $\min_{(\beta_0, \beta_1) \in \mathbb{R}^2} SCR(\beta_0, \beta_1)$

$$\frac{\partial SCR}{\partial \beta_1} (\beta_0, \beta_1) = \sum_{i=1}^n 2(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) (-X_i) \quad (-1)$$

$$= -2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)$$

$$= -2 \left\{ \sum_{i=1}^n Y_i - \sum_{i=1}^n \hat{\beta}_0 - \sum_{i=1}^n \hat{\beta}_1 X_i \right\}$$

$$= -2 \{ \bar{Y} - n \hat{\beta}_0 - n \hat{\beta}_1 \bar{X} \}$$

$$\frac{\partial SCR}{\partial \beta_0} (\beta_0, \beta_1) = \sum_{i=1}^n 2(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) (-1)$$

$$= -2 \left\{ \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n \hat{\beta}_0 X_i - \sum_{i=1}^n \hat{\beta}_1 X_i^2 \right\}$$

$$= -2 \left\{ \sum_{i=1}^n X_i Y_i - n \hat{\beta}_0 \bar{X} - \hat{\beta}_1 \sum_{i=1}^n X_i^2 \right\}$$

Aquí, igualamos ambas ecuaciones a cero y resulta que

$$\frac{\partial SCR}{\partial \beta_1} = 0 \Leftrightarrow \left\{ \begin{array}{l} n \bar{Y} - n \hat{\beta}_0 - n \hat{\beta}_1 \bar{X} = 0 \\ \sum_{i=1}^n X_i Y_i - n \hat{\beta}_0 \bar{X} - \hat{\beta}_1 \sum_{i=1}^n X_i^2 = 0 \end{array} \right.$$

$$\frac{\partial SCR}{\partial \beta_0} = 0 \Leftrightarrow \left\{ \begin{array}{l} \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \\ \sum_{i=1}^n X_i Y_i = n \hat{\beta}_0 \bar{X} + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \end{array} \right.$$

Despejamos la segunda ecuación, nos sustituir la primera

$$\begin{aligned} \sum_{i=1}^n X_i Y_i &= n (\bar{Y} - \hat{\beta}_1 \bar{X}) \bar{X} + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \\ &= n \bar{X} \bar{Y} - n \hat{\beta}_1 \bar{X}^2 + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \\ &= n \bar{X} \bar{Y} + \hat{\beta}_1 \left\{ -n \bar{X}^2 + \sum_{i=1}^n X_i^2 \right\} \end{aligned}$$

$$\text{Así, } \hat{\beta}_1 = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2}$$

$$\text{y así, } \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Ahora, veamos que son mínimos, con la Hessiana

$$\frac{\partial^2 (SC)}{\partial \beta_1^2} = -2(-n) = 2n$$

$$\frac{\partial^2 (SC)}{\partial \beta_0 \partial \beta_1} = -2(-n \bar{X}) = 2n \bar{X} = \frac{\partial^2 (SC)}{\partial \beta_0^2}$$

$$\frac{\partial^2 (SC)}{\partial \beta_1^2} = -2 \sum_{i=1}^n (X_i - \bar{X})^2 = 2 \sum_{i=1}^n X_i^2$$

Cauchonnes la Hessiana

$$H(SC)(b_0, b_1) = \begin{pmatrix} 2n & 2n \bar{X} \\ 2n \bar{X} & 2 \sum_{i=1}^n X_i^2 \end{pmatrix}$$

Utilizamos el criterio de Sylvester con menores principales para ver si es definida positiva

$$|H| = 2n > 0$$

$$|H| = 4n \sum_{i=1}^n X_i^2 - 4n \bar{X}^2 = 4n (\sum_{i=1}^n X_i^2 - n \bar{X}^2)$$

Veamos si  $|H| > 0$ .

$$\sum_{i=1}^n X_i^2 - n \bar{X}^2 = \sum_{i=1}^n X_i^2 - 2n \bar{X}^2 + n \bar{X}^2$$

$$= \sum_{i=1}^n X_i^2 - 2n \frac{1}{n} \sum_{i=1}^n X_i + n \bar{X}^2 = \sum_{i=1}^n X_i^2 - 2 \sum_{i=1}^n X_i \bar{X} + \sum_{i=1}^n (\bar{X})^2$$

$$= \sum_{i=1}^n (X_i - \bar{X})^2 > 0$$

Ahora,  $|H| = 4n (\sum_{i=1}^n X_i^2 - n \bar{X}^2) > 0$ , por lo que

$$b_0 = \bar{Y} - b_1 \bar{X}, \quad b_1 = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2} \text{ minimiza el SC}$$

Ahora bien,  $b_0, b_1 = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sum_{i=1}^n X_i^2 - n \bar{X}^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$

Y vemos que  $\sum_{i=1}^n X_i^2 - n \bar{X}^2 = \sum_{i=1}^n (X_i - \bar{X})^2$ , así basta estudiar el numerador,

$$\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y} = \sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y} - n \bar{X} \bar{Y} + n \bar{X} \bar{Y}$$

$$= \sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y} - n \bar{X} \bar{Y} + n \bar{X} \bar{Y} + \sum_{i=1}^n \bar{X} \bar{Y}$$

$$= \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \bar{Y} - \sum_{i=1}^n \bar{X} Y_i + \sum_{i=1}^n \bar{X} \bar{Y}$$

$$= \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \bar{Y} - \sum_{i=1}^n \bar{X} Y_i + \sum_{i=1}^n \bar{X} \bar{Y}$$

$$= \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \bar{Y} - \sum_{i=1}^n \bar{X} Y_i + \sum_{i=1}^n \bar{X} \bar{Y}$$

De este modo, vemos que

$$\begin{cases} \sum x_i y_i - n \bar{x} \bar{y} = \sum (x_i - \bar{x})(y_i - \bar{y}) \\ \sum x_i^2 - n \bar{x}^2 = \sum (x_i - \bar{x})^2 \end{cases}$$

$$Así, b_0 = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Asimismo,

$$\begin{aligned} b_1 &= \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} = \frac{n \left\{ \sum x_i y_i - n \bar{x} \sum x_i - n \bar{y} \sum y_i \right\}}{n \left\{ \sum x_i^2 - n \bar{x}^2 - n \sum x_i^2 + n \bar{x}^2 \right\}} \\ &= \frac{n \sum x_i y_i - \sum y_i \sum x_i}{n \sum x_i^2 - (\sum x_i)^2} \end{aligned}$$

### Otra Forma

Construva  $b_1 = \frac{s_{xy}}{s_x^2}$

$$\begin{aligned} b_1 &= \frac{\left( \sum x_i y_i - \sum x_i \left( \frac{1}{n} \sum x_i \right) \right)}{\left( \sum y_i^2 - \frac{1}{n} (\sum x_i)^2 \right)} = \frac{\sum x_i y_i - \frac{1}{n} \sum x_i \sum y_i}{\sum x_i^2 - \frac{1}{n} (\sum x_i)^2} \\ &= \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \end{aligned}$$

Ahora 2.2  $\left( \begin{array}{l} b_0 = \bar{y} - b_1 \bar{x} \\ p.d. \sum (y_i - \hat{y}_i) \hat{y}_i = 0 \quad b_1 = \frac{s_{xy}}{s_{xx}} \end{array} \right)$

$$\sum (y_i - \hat{y}_i) \hat{y}_i = \sum e_i \hat{y}_i = \sum e_i (b_0 + b_1 x_i)$$

$$= b_1 \sum e_i + b_0 \sum e_i x_i \stackrel{(*)}{=} \textcircled{C} \stackrel{(**)}{=}$$

Vemos que

$$\sum e_i = \sum (y_i - \hat{y}_i) = \sum (y_i - b_0 - b_1 x_i) = \sum y_i - n b_0 - b_1 \sum x_i = 0 \quad (*)$$

Asimismo,  $\sum e_i x_i = \sum x_i (y_i - \hat{y}_i) = \sum x_i (y_i - b_0 - b_1 x_i)$

$$= \sum x_i y_i - n \sum x_i - b_1 \sum x_i^2 = \sum x_i y_i - b_1 n \bar{x} - b_1 \sum x_i^2$$

$$= \sum x_i y_i - (\bar{y} - b_1 \bar{x}) n \bar{x} - b_1 \sum x_i^2$$

$$= \sum x_i y_i - n \bar{x} \bar{y} + b_1 n \bar{x}^2 - b_1 \sum x_i^2$$

$$= \sum x_i y_i - n \bar{x} \bar{y} - b_1 (\sum x_i^2 - n \bar{x}^2)$$

$$= \sum x_i y_i - n \bar{x} \bar{y} - \left\{ \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} \right\} (\sum x_i^2 - n \bar{x}^2)$$

$$= \textcircled{O} \quad (**)$$

Conjetura

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \hat{y})$$

$$\begin{aligned} \sum (x_i - \bar{x})(y_i - \bar{y}) &= \sum x_i y_i - n \bar{x} \bar{y} \\ &= \sum x_i y_i - n \bar{x} \sum y_i - \bar{x} \sum y_i = \sum x_i y_i - \bar{x} \sum y_i \\ &= \sum x_i y_i - \sum y_i \bar{x} = \sum x_i y_i - \bar{x} \bar{y} - \sum (x_i - \bar{x}) y_i \end{aligned}$$

3. A partir de una muestra de  $n = 200$  parejas de observaciones, se calcularon las siguientes cantidades:

$$\sum X_i = 11.34, \sum Y_i = 20.72, \sum X_i^2 = 12.16, \sum Y_i^2 = 84.96 \text{ y } \sum X_i Y_i = 22.13$$

Con base en estas cantidades, estime las dos regresiones

$$\hat{Y}_i = b_0 + b_1 X_i \quad y \quad \hat{X}_i = a_0 + a_1 Y_i.$$

Deduzca una recta estimada para  $Y$  a partir de la segunda ecuación.

Grafique las dos rectas estimadas de  $Y$  en la misma gráfica y comente acerca de ellas, en particular acerca de cómo se podrían interpretar las mismas y por qué difieren.

Recordemos que

$$\begin{aligned} b_0 &= \bar{y} - b_1 \bar{x} \quad y \quad b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \\ &= \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \\ &= \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} \end{aligned}$$

Así pues,

$$b_0 = \frac{200 (22.13) - (11.34) (20.72)}{200 (12.16) - (11.34)^2} = 1.819496047$$


Así pues,

$$b_1 = \frac{1}{200} (20.72) - \frac{b_0}{200} (11.34) = 4.34574146 \times 10^{-4}$$


Ahora grafiquemos los dos rectos de  $\hat{Y}$  y  $\hat{x}$  en la  
misma gráfica

$$\textcolor{green}{\hat{Y}} = 0.000495776482 + 1.834846146 \hat{x} \quad \textcircled{1}$$

$$\textcolor{blue}{\hat{x}} = \hat{x} - \frac{0.0122740053}{0.428913574} \quad \textcircled{2}$$




Al estimar  $\alpha$  o  $\beta$  a partir de  $X$  y  $\alpha$  o  $\beta$  a partir de  $Y$   
resulta en vectores distintos. Para verlo mejor,  
superponemos un diagrama de dispersión.



Cuando estimamos  $\alpha$  o  $\beta$  a través de  $X$  por el modelo  $\hat{Y}_i = \beta_0 + \beta_1 x_i + \varepsilon_i$   
utilizamos Mínimos Cuadrados ó ptimes

$$\min_{(\beta_0, \beta_1) \in \mathbb{R}^2} S.C.R. = \min_{(\beta_0, \beta_1) \in \mathbb{R}^2} \sum_{i=1}^n (\hat{Y}_i - (\beta_0 + \beta_1 x_i))^2$$

que minimiza la distancia entre uno vector de estimación con los valores  
 $\hat{Y}_i$ . Como se ve adelante.



Por otro lado, si estimamos  $X$  a partir de  $Y$  con

$X_i = \alpha_0 + \alpha_1 Y_i$  haremos la misma estimación  $\hat{\alpha}_0$ ,  
minimizando cuadrados pero ahora es

$$\min_{(\alpha_0, \alpha_1) \in \mathbb{R}^2} \widehat{S.C.R.} = \min_{(\alpha_0, \alpha_1) \in \mathbb{R}^2} \sum_{i=1}^n (x_i - (\alpha_0 + \alpha_1 y_i))^2$$

que minimiza la distancia entre un vector de estimación con los valores  
 $x_i$ . Como se ve adelante.



Como se minimizar  
distancias de Fuentes se  
obtienen vectores distintos.