

# Tarea #4

## EQUIPO #3

Sofía Alejandra Díaz Miranda 172360  
David Isaac López Romero 173993  
Sofía Oliva Ruiz 164595  
Adriana Alavez Lujano 163480  
Diego Carlos Krafft de Silva 173246

Se pretende explicar el ingreso a través de la edad y el género de la persona, así que:

- Ajuste un modelo** de regresión lineal simple para los hombres y otro para las mujeres. En cada caso, proporcione los resultados que considere más relevantes e intérpretelos.
- Para cada una de las regresiones del inciso anterior, **realice un análisis** de residuos y, de ser posible, **obtenga un mejor modelo**.

Resultados para a) y b):

Regresión Hombres:

SUMMARY OUTPUT								
Regression Statistics								
Multiple R	0.933190961							
R Square	0.870845369							
Adjusted R Square	0.79335259							
Standard Error	20666.36556							
Observations	9							
ANOVA								
	df	SS	MS	F	Significance F			
Regression	3	14398898895	4799632965	11.23776156	0.011634241			
Residual	5	2135493327	427098665.4					
Total	8	16534392222						
	Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 95.0%	Upper 95.0%
Intercept	-1149950.833	434005.3922	-2.649623378	0.045447014	-2265597.211	-34304.45564	-2265597.211	-34304.45564
Persona	-393484.1667	132770.4371	-2.963642926	0.03138655	-734781.4405	-52186.89281	-734781.4405	-52186.89281
Edad	80215	26199.40017	3.061711317	0.02804727	12867.29782	147562.7022	12867.29782	147562.7022
Género	0	0	65535	#N!NUM!	0	0	0	0

Nuestro modelo se explica 87.08 %.

Tenemos  $\beta_{\text{persona}} = -393484.1667$  Error estándar = 20666.36556  
 $\beta_{\text{edad}} = 80215$   
 $\beta_{\text{género}} = 0$

En cuanto al inciso b), podemos ver específicamente la tabla de ANOVA, donde se ven los grados de libertad ( $3+5=8$ ) y suma de cuadrados 16534392222.

# Regresión Mujeres :

## SUMMARY OUTPUT

Regression Statistics	
Multiple R	0.944111619
R Square	0.891346748
Adjusted R Square	0.826154797
Standard Error	6761.191043
Observations	9

ANOVA					
	df	SS	MS	F	Significance F
Regression	3	1875082478	625027492.8	13.67265029	0.007613081
Residual	5	228568521.6	45713704.32		
Total	8	2103651000			

	Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 95.0%	Upper 95.0%
Intercept	1388830.595	249260.7279	5.571798681	0.002564617	748085.4957	2029575.695	748085.4957	2029575.695
Persona	-220476.3095	43437.06625	-5.075764285	0.00384822	-332134.843	-108817.776	-332134.843	-108817.776
Edad	44165.35714	8571.374066	5.152657766	0.003606845	22131.93866	66198.77562	22131.93866	66198.77562
Género	0	0	65535	#N!NUM!	0	0	0	0

Nuestro modelo se explica 89.13%

Tenemos  $\beta_{\text{persona}} = -220476.3095$  Error estándar = 6761.191043  
 $\beta_{\text{edad}} = 44165.3514$   
 $\beta_{\text{género}} = 0$

En cuanto al inciso b), podemos ver específicamente la tabla de ANOVA, donde se ven los grados de libertad ( $3+5=8$ ) y suma de cuadrados 2103651000.

- b) El ajuste que realizamos fue agregar una nueva variable explicativa. Agregamos la edad al cuadrado y al hacerlo se reduce la tendencia cuadrática de los residuos.

- c) Considere ahora un modelo de regresión en donde aparezcan las 18 observaciones e **incluya la variable género**. ¿Cómo se interpreta el coeficiente de esta variable?

Tenemos que calcular  $b = (X'X)^{-1} X'Y$

$$X = \begin{pmatrix} 1 & 21 & 441 & 1 \\ 1 & 27 & 729 & 1 \\ 1 & 32 & 1024 & 1 \\ 1 & 37 & 1369 & 1 \\ 1 & 42 & 1764 & 1 \\ 1 & 47 & 2209 & 1 \\ 1 & 52 & 2704 & 1 \\ 1 & 57 & 3249 & 1 \\ 1 & 62 & 3844 & 1 \\ 1 & 21 & 3844 & 0 \\ 1 & 27 & 941 & 0 \\ 1 & 32 & 729 & 0 \\ 1 & 37 & 1024 & 0 \\ 1 & 42 & 1369 & 0 \\ 1 & 47 & 1764 & 0 \\ 1 & 52 & 2209 & 0 \\ 1 & 57 & 2704 & 0 \\ 1 & 62 & 3249 & 0 \end{pmatrix} \quad Y = \begin{pmatrix} 141,080 \\ 205,230 \\ 224,710 \\ 260,170 \\ 273,140 \\ 280,930 \\ 272,880 \\ 267,060 \\ 259,510 \\ 111,540 \\ 145,170 \\ 162,150 \\ 161,990 \\ 157,770 \\ 159,060 \\ 162,170 \\ 157,550 \\ 152,400 \end{pmatrix} \quad b = \begin{pmatrix} -102805.525 \\ 11584.1381 \\ -119.550586 \\ 90545.5556 \end{pmatrix}$$

$$\therefore \hat{y} = \hat{Y} = -102805.52 + 11584.13 * \text{edad} - 119.55 * \text{edad}^2 + 90545 * \text{Género}$$

El coeficiente lo podemos interpretar como la diferencia que gana un hombre o mujer solo por el género

- d) **Realice** un análisis de varianza con el modelo del inciso previo. ¿Se podría decir que el coeficiente asociado con la variable género es diferente de cero?

Values	
ebarra	6863.60482016762
edad	num [1:18] 21 27 32 37 42 47 52 57 62 21 ...
eiAnterior	num [1:17] -32613 11703 14654 33586 30027 ...
eiNueva	num [1:17] 11703 14654 33586 30027 21289 ...
esum	123544.886763017
FdeR	3.28738210463651
gen	num [1:18] 1 1 1 1 1 1 1 1 1 0 ...
i	17
ingreso	num [1:18] 141080 205230 224710 260170 273140 ...
ingresoBarra	197472.777777778
n	18L
per	int [1:18] 1 2 3 4 5 6 7 8 9 10 ...

Data	
b	num [1:2, 1] 3306 104273
CME	num [1, 1] 2.46e+11
CMR	num [1, 1] 1.39e+09
e	num [1:18, 1] -32613 11703 14654 33586 30027 ...
Fcalculada	num [1, 1] 176
m	num [1:2, 1:2] 34666 377 377 9
m1	num [1:2, 1:2] 0.000053 -0.002219 -0.002219 0.20408
m2	num [1:2, 1] 1.54e+08 2.18e+06
p_value	num [1, 1] 6.41e-12
R	num [1, 1] 0.0276
SCE	num [1, 1] 7.37e+11
SCR	num [1, 1] 2.09e+10
SCT	num [1, 1] 7.57e+11
SCTformula	num [1, 1] 7.57e+11
x	num [1:2, 1:18] 21 1 27 1 32 1 37 1 42 1 ...
X	num [1:18, 1:2] 21 27 32 37 42 47 52 57 62 21 ...
Yg	num [1:18, 1] 173693 193527 210056 226584 243113 ...

Tendríamos que restringir el modelo a solo género para verificarlo

- e) **Pronostique** el ingreso para un hombre de 33 años y para una mujer de la misma edad.

Con el modelo  $\hat{Y} = -102805.52 + 11584.13 * \text{Edad} - 119.55 * \text{edad}^2 + 90845 * \text{género}$   
 Hombre 33 (Género = 1)

$$\hat{Y} = -102805.52 + 11584.13 * 33 + -119.55 * 1089 + 90845$$


El ingreso estimado será 240,128.82

Mujer 33 (Género = 0)


$$\hat{Y} = -102805.52 + 11584.13 * 33 + -119.55 * 1089 + 90845 * 0$$

El ingreso estimado será 149283.82

f) **Verifique** todos los supuestos del modelo del inciso c).



Gráfica de  $e_i$  con  $e_{i+1}$ , se ve que hay autocorrelación porque hay una ligera tendencia lineal no capturada por el modelo. Son correlacionados en alguna medida porque hay una tendencia lineal que no capturamos.



Gráfica de los valores estimados con los errores para verificar si hay varianza constante o no. Vemos que la varianza no es constante.