

(Tarea 3) Estadística Aplicada III

David Isaac López Romero

CU: 173993

1) Tenemos la siguiente matriz

	a	b	c	d	e
a		2	1	3	4
b			2	5	3
c					
d					3
e					

Haz el análisis de cúmulos utilizando:

a) Distancia Mínima.

①

	{a}	{b}	{c}	{d}	{e}
{a}		2	1	3	4
{b}			2	5	3
{c}				3	4
{d}					3
{e}					

⇒

②

	{a, c}	{b}	{d}	{e}
{a, c}		2	3	4
{b}			5	3
{d}				3
{e}				

③

	{a, b, c}	{d}	{e}
{a, b, c}		3	3
{d}			3
{e}			

$d \leq 1$, {a}, {b}, {c}, {d}, {e}
 $1 \leq d \leq 2$, {a, c}, {b}, {d}, {e}
 $2 \leq d \leq 3$, {a, b, c}, {d}, {e}
 $3 \leq d$, {a, b, c, d}, {e}


• 5 grupos: {a}, {b}, {c}, {d}, {e} ($d \leq 1$)

• 4 grupos: {a, c}, {b}, {d}, {e} ($1 \leq d \leq 2$)

• 3 grupos: {a, b, c}, {d}, {e} ($2 \leq d \leq 3$)

• 1 grupo: {a, b, c, d, e} ($3 \leq d$)

Dendograma



b) Distancia máxima

①

	a	b	c	d	e
a		2	1	3	4
b			2	5	3
c				3	4
d					3
e					

②

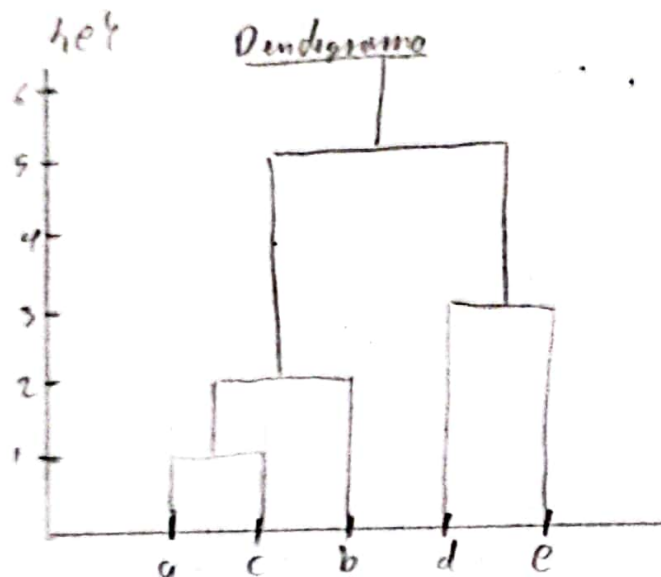
	a,c	b	d	e
a,c		2	3	4
b			5	3
d				3
e				

③

	a,b,c	d	e
a,b,c		5	4
d			3
e			

④

	a,b,c,d	e
a,b,c,d		5
e		



- 1 $d < 1$ a, b, c, d, e
- 1 $1 \leq d < 2$ a, c, b, d, e
- 1 $2 \leq d < 3$ a, b, c, d, e
- 1 $3 \leq d < 5$ a, b, c, d, e
- 1 $5 \leq d$ a, b, c, d, e

- 5 grupos: a, b, c, d, e (d < 1)
- 4 grupos: a, c, b, d, e (1 ≤ d < 2)
- 3 grupos: a, b, c, d, e (2 ≤ d < 3)
- 2 grupos: a, b, c, d, e (3 ≤ d < 5)
- 1 grupo: a, b, c, d, e (5 ≤ d)

c) Distància Mitjana

①	a, b	a, c	a, d	a, e	⇒	a, c	a, b	a, d	a, e	③
a, b		2	1	3	4	a, c		2	3	1
a, c			2	5	3	a, b			5	3
a, d				3	4	a, d				3
a, e					3	a, e				

$$d(a, c, b) = \frac{d(a, b) + d(c, b)}{2} = \frac{2 + 1}{2} = 1.5$$

$$d(a, c, d) = \frac{d(a, d) + d(c, d)}{2} = \frac{3 + 2}{2} = 2.5$$

$$d(a, c, e) = \frac{d(a, e) + d(c, e)}{2} = \frac{4 + 3}{2} = 3.5$$


⇒	a, b, c	a, d	a, e	⇒	a, b, c	a, d, e
a, b, c		4	3.5	a, b, c		3.75
a, d			3	a, d, e		
a, e						

$$d(a, c, b, d) = \frac{d(a, c, b) + d(b, d)}{2} = \frac{1.5 + 1}{2} = 1.25$$

$$d(a, c, b, e) = \frac{d(a, c, b) + d(b, e)}{2} = \frac{1.5 + 3}{2} = 2.25$$

$$d(a, b, c, d, e) = \frac{d(a, b, c, d) + d(a, b, c, e)}{2} = \frac{1.25 + 2.25}{2} = 1.75$$

Dendrograma



- $d < 1$, a, c
- $1 \leq d < 2$, a, c, b
- $2 \leq d < 3$, a, b, c
- $3 \leq d < 3.75$, a, b, c, d
- $3.75 \leq d$, a, b, c, d, e

- 5 grupos: $\{a\}, \{b\}, \{c\}, \{d\}, \{e\}$ ($d \leq 1$)
- 4 grupos: $\{a, c\}, \{b\}, \{d\}, \{e\}$ ($1 \leq d \leq 2$)
- 3 grupos: $\{a, b, c\}, \{d\}, \{e\}$ ($2 \leq d \leq 3$)
- 2 grupos: $\{a, b, c\}, \{d, e\}$ ($3 \leq d \leq 3.75$)
- 1 grupo: $\{a, b, c, d, e\}$ ($3.75 \leq d$)

2) Sea A matriz de tamaño $m \times n$. Definimos $\|A\|_2 = \max \|Ax\|_2$ s.a. $\|x\|_2 = 1$ con x vector de tamaño $n \times 1$. Demuestra que:

$$\|A\|_2 = \max(\sqrt{\lambda}) \text{ con } \lambda \text{ eigenvalor de la matriz } A^T A.$$

Dem:
Calculamos $\|A\|_2^2 = (\max \|Ax\|_2)^2$ s.a. $\|x\|_2^2 = 1$

Tenemos el problema

$$\max \|Ax\|_2^2 \Leftrightarrow \max x^T A^T A x$$

$$\text{s.a. } \|x\|_2^2 = 1 \quad \text{s.a. } x^T x = 1$$

Consideramos al Lagrangiano

$$\mathcal{L}(x, \lambda) = x^T A^T A x - \lambda (x^T x - 1)$$

Así, vemos que

$$\frac{\partial \mathcal{L}}{\partial x}(x, \lambda) = 0 \Leftrightarrow 2A^T A x - 2\lambda x = 0 \Leftrightarrow A^T A \bar{x} = \lambda \bar{x}$$

Por lo tanto, λ es eigenvalor de $A^T A$ y \bar{x} su eigenvector respectivo.

Ahora bien, si definimos $y = x^T A^T A x$ tenemos que ($A^T A$ es definida positiva)

$$\text{Var}(x^T A^T A x) = x^T (A^T A x) = x^T \lambda x = \lambda (x^T x) = \lambda$$

el cual es máximo para el eigenvalor máximo. Es decir,

$$\lambda = \max_{i=1, \dots, n} \{\lambda_i\} = \max \{\text{eigenvalores de } A^T A\}$$

En consecuencia,

$$\|A\|_2^2 = \max(\lambda) \text{ con } \lambda \text{ eigenvalor de } A^T A$$

$$\Leftrightarrow \|A\|_2 = \max(\sqrt{\lambda}) \text{ con } \lambda \text{ eigenvalor de } A^T A$$

$$\therefore \|A\|_2 = \max(\sqrt{\lambda}) \text{ con } \lambda \text{ eigenvalor de } A^T A$$

3) Tenemos el siguiente modelo para la probabilidad de que una persona vaya a votar por uno de los siguientes candidatos:

- 1) Clinton
- 2) Bush H
- 3) Perrot

$$\ln\left(\frac{p_{2i}}{p_{1i}}\right) = -0.35 + 0.88 H_i + 0.47 U_{1i}$$

$$\ln\left(\frac{p_{3i}}{p_{1i}}\right) = -0.52 - 0.32 H_i + 0.17 U_{1i}$$

H_i es una variable indicadora que toma el valor de 1 si es Hombre y 0 en otro caso de mujer

U_{1i} es una variable indicadora que toma el valor de 1 si tiene estudios universitarios y 0 en otro caso.

4) Interpreta los coeficientes

I) El cambio entre Clinton y Bush aumenta $(e^{0.88} - 1) \times 100\% = 171.0899\%$ por pasar de mujer a hombre.

II) El cambio entre Clinton y Bush aumenta $(e^{0.47} - 1) \times 100\% = 59.4999\%$ por pasar de no tener estudios universitarios a sí tenerlos

III) El cambio entre Clinton y Perrot disminuye en $(e^{-0.32} - 1) \times 100\% = -27.39\%$ por pasar de mujer a hombre.

IV) El cambio entre Clinton y Perrot disminuye en $(e^{-0.17} - 1) \times 100\% = -15.633\%$ por pasar de no tener estudios universitarios a sí tenerlos.

b) Encuentra la probabilidad de que vote por cada uno de los candidatos para todos los perfiles.

I) Hombre con estudios universitarios

Clinton: $\hat{p}_1 = \frac{1}{1 + e^{-0.35 + 0.88 + 0.47} + e^{-0.52 - 0.32 - 0.17}} = 0.277978$

Bush H: $\hat{p}_2 = \frac{e^{-0.35 + 0.88 + 0.47}}{1 + e^{-0.35 + 0.88 + 0.47} + e^{-0.52 - 0.32 - 0.17}} = 0.665837$

Perrot: $\hat{p}_3 = \frac{e^{-0.52 - 0.32 - 0.17}}{1 + e^{-0.35 + 0.88 + 0.47} + e^{-0.52 - 0.32 - 0.17}} = 0.089215$

II) Hombre sin estudios universitarios

Clinton: $\hat{p}_1 = \frac{1}{1 + e^{-0.35 + 0.88} + e^{-0.52 - 0.32}} = 0.319123$

Bush H: $\hat{p}_2 = \frac{e^{-0.35 + 0.88}}{1 + e^{-0.35 + 0.88} + e^{-0.52 - 0.32}} = 0.542678$

Perrot: $\hat{p}_3 = \frac{e^{-0.52 - 0.32}}{1 + e^{-0.35 + 0.88} + e^{-0.52 - 0.32}} = 0.137898$

III) Mujer con estudios universitarios

Clinton: $\hat{p}_1 = \frac{1}{1 + e^{-0.35 + 0.47} + e^{-0.52 - 0.17}} = 0.380362$

Bush H: $\hat{p}_2 = \frac{e^{-0.35 + 0.47}}{1 + e^{-0.35 + 0.47} + e^{-0.52 - 0.17}} = 0.428857$

Perrot: $\hat{p}_3 = \frac{e^{-0.52 - 0.17}}{1 + e^{-0.35 + 0.47} + e^{-0.52 - 0.17}} = 0.190781$

IV) Mujer sin estudios universitarios

Clinton: $\hat{p}_1 = \frac{1}{1 + e^{-0.35} + e^{-0.52}} = 0.434932$

Bush H: $\hat{p}_2 = \frac{e^{-0.35}}{1 + e^{-0.35} + e^{-0.52}} = 0.306492$

Perrot: $\hat{p}_3 = \frac{e^{-0.52}}{1 + e^{-0.35} + e^{-0.52}} = 0.258576$

4) $\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \sim N_3 \left(\begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 2 & 1 & 3 \\ 1 & 4 & 5 \\ 3 & 5 & 8 \end{pmatrix} \right)$

a) Encuentra la distribución condicional de x_3 dado que $x_1=1$, $x_2=2$

Definimos a $\underline{x}_1 = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$, $\underline{x}_2 = (x_3)$

Sabemos que $\underline{x}_2 | \underline{x}_1 \sim N(\underline{\mu}_2 + \underline{\Sigma}_{21} \underline{\Sigma}_{11}^{-1} (\underline{x}_1 - \underline{\mu}_1), \underline{\Sigma}_{22} - \underline{\Sigma}_{21} \underline{\Sigma}_{11}^{-1} \underline{\Sigma}_{12})$

donde $\underline{\mu}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ $\underline{\Sigma}_{11} = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$ $\underline{\Sigma}_{12} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$ entonces
 $\underline{\mu}_2 = 2$ $\underline{\Sigma}_{21} = (3 \ 5)$ $\underline{\Sigma}_{22} = (8)$

$$\begin{aligned} \mu_{x_2 | x_1} &= \underline{\mu}_2 + \underline{\Sigma}_{21} \underline{\Sigma}_{11}^{-1} (\underline{x}_1 - \underline{\mu}_1) = 2 + (3 \ 5) \frac{1}{7} \begin{pmatrix} 4 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} \\ &= 2 + \frac{1}{7} (7, 7) \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} = 2 + (1, 1) \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} = x_1 + x_2 - 2 \end{aligned}$$

$$\therefore \mu_{x_2 | x_1} = x_1 + x_2 \quad \xRightarrow{x_1=1, x_2=2} \mu_{x_2 | x_1} = 3$$

$$\begin{aligned} Z_{x_2|x_1} &= Z_{22} - Z_{21} Z_{11}^{-1} Z_{12} = 8 - (3 \ 5) \frac{1}{7} \begin{pmatrix} 4 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ 5 \end{pmatrix} \\ &= 8 - \frac{1}{7} (7, 7) \begin{pmatrix} 3 \\ 5 \end{pmatrix} = 8 - (1, 1) \begin{pmatrix} 3 \\ 5 \end{pmatrix} = 8 - 8 = 0 \end{aligned} \quad (8)$$

Así, $Z_{x_2|x_1} = 0 \quad \forall (x_1, x_2) \in S_{x_1, x_2}$

$\therefore X_2 | X_1=1, X_2=2 \sim N(3, 0)$

Como $Z_{x_2|x_1}=0$ resulta que $X_2 | X_1=1, X_2=2 \equiv 3$ (constante)

b) Encuentra la distribución de $X_1 + X_2 - X_3$

Definimos $Y = X_1 + X_2 - X_3$ Vamos que

$$Y = X_1 + X_2 - X_3 = (1, 1, -1) \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix} = A X, \quad A = (1, 1, -1)$$

$$X = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}$$

entonces,

$$Y \sim N(A \mu_x + A Z_x A^T)$$

por lo que,

$$\mu_Y = A \mu_x = (1, 1, -1) \begin{pmatrix} 1 \\ 1 \\ 2 \end{pmatrix} = 0$$

$$Z_Y = A Z_x A^T = (1, 1, -1) \begin{pmatrix} 2 & 1 & 3 \\ 1 & 4 & 5 \\ 3 & 5 & 8 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = (1, 1, 1) \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} = 0$$

Así pues,

$$Y \sim N(0, 0)$$

Pero, como $Z_Y=0$, resulta que $Y = X_1 + X_2 - X_3 \equiv 0$ (constante)

5) Tenemos las siguientes variables estandarizadas:

	Componente Principal 1	Componente Principal 2
Física	0.55	-0.02
Química	0.50	0.23
Educación Física	0.02	0.02
Literatura	-0.13	0.85
Inglés	-0.15	0.84

Los eigenvalores son 3 y 1.5.

a) Interpreta los componentes Principales, obtén la correlación de las variables con los componentes principales.

Componente Principal 1: Ciencias exactas

Componente Principal 2: Lenguas

Como están estandarizadas, $\sigma^2 = 1$

Correlación $\rho(x_i, y_j) = \frac{\sum a_{ij}}{\sigma_i \sigma_j} = \sqrt{1} \cdot a_{ij} = \sqrt{1} \cdot a_{ij}$

Variable	Primera componente	Segunda componente
Física	0.952628	-0.024495
Química	0.866025	0.281641
Educación Física	0.034641	0.024495
Literatura	-0.225167	1.04103
Inglés	-0.259808	1.02879

• Las variables más correlacionadas con el componente principal son Física y Química

• Las variables más correlacionadas con el componente principal son Literatura e Inglés.

b) ¿Qué porcentaje de la varianza explican los primeros dos componentes principales? (10)

	λ_j	$\frac{\lambda_j}{\text{Var total}}$	% Var	acumulado	% Acumulado
Componente 1	3	$3/5 = 0,6$	60%	3	60%
Componente 2	1,5	$1,5/5 = 0,3$	30%	4,5	30%

c) Si las calificaciones estandarizadas de un alumno son las siguientes, ubícalo en el plano cartesiano de los primeros dos componentes principales.

Componente Principal 1

Física	0.15
Química	0.12
Educación Física	0.22
Literatura	-0.03
Inglés	-0.05

$$\text{Comp 1: } (0.15)(0.55) + (0.12)(0.50) + (0.22)(0.02) + (-0.03)(-0.13) + (-0.05)(-0.15) = 0.1583$$

$$\text{Comp 2: } (0.15)(-0.07) + (0.12)(0.23) + (0.22)(0.02) + (-0.03)(0.85) + (-0.05)(0.84) = -0.0385$$

